

Metody Obliczeniowe w Nauce i Technice

Sprawozdanie | Układy równań liniowych – metody bezpośrednie

Katarzyna Piskorz | Informatyka

1. Wstęp teoretyczny i omówienie przypadku

W ramach laboratorium przeprowadzono analizę numerycznego rozwiązywania układów równań liniowych postaci:

$$Ax = b$$

gdzie:

- A – kwadratowa macierz współczynników układu o wymiarach $n \times n$,
- x – wektor kolumnowy poszukiwanych niewiadomych o długości n ,
- b – wektor wyrazów wolnych o długości n .

Celem pracy było zbadanie wpływu uwarunkowania macierzy oraz precyzji obliczeń (`float32` vs `float64`) na dokładność rozwiązań, a także porównanie klasycznej eliminacji Gaussa z algorytmem Thomasa. Badaniom poddano trzy rodzaje macierzy, zdefiniowane poniżej (w każdym przypadku i oraz j oznaczają odpowiednio indeks wiersza i indeks kolumny macierzy, przyjmujące wartości od 1 do n):

Macierz I (zbliżona do macierzy Hilberta):

$$A_1 = \begin{cases} a_{1j} = 1 \\ a_{ij} = \frac{1}{i+j-1} \end{cases} \quad \text{dla } i \neq 1$$

Gdzie a_{ij} stanowi pojedynczy element macierzy A_1 . Wzór ten tworzy macierz o szybko malejących ułamkach w miarę przesuwania się w dół i w prawo po siatce elementów.

Macierz II:

$$A_2 = \begin{cases} a_{ij} = \frac{2i}{j} & \text{dla } j \geq i \\ a_{ij} = a_{ji} & \text{dla } j < i \end{cases}$$

Gdzie a_{ij} to wyraz macierzy A_2 . Drugi warunek gwarantuje jej symetryczność względem głównej przekątnej.

Macierz III (trójdzielna, parametry indywidualne $k = 5, m = 4$):

$$A_3 = \begin{cases} a_{i,i} = -4i - 5 \\ a_{i,i-1} = \frac{i}{4} & \text{dla } i > 1 \\ a_{i,i+1} = \frac{i}{4} & \text{dla } i < n \\ a_{i,j} = 0 & \text{dla } j < i - 1 \text{ oraz } j > i + 1 \end{cases}$$

W macierzy trójdzielnej A_3 niezerowe elementy występują wyłącznie na głównej przekątnej ($a_{i,i}$), bezpośrednio pod nią ($a_{i,i-1}$) oraz bezpośrednio nad nią ($a_{i,i+1}$). Pozostałe elementy ($a_{i,j}$ dla $|i - j| > 1$) są równe zero.

2. Metodyka badawcza

Do weryfikacji poprawności zaimplementowanych algorytmów zastosowano tzw. metodę odwróconą. Polega ona na ustaleniu prawdziwego wyniku z góry. Wprowadzono wektor rzeczywisty x_{zad} , składający się z n -elementowej permutacji wartości ze zbioru $\{1, -1\}$. Następnie na jego podstawie wyliczano sztuczny wektor wyrazów wolnych b :

$$b = A \cdot x_{\text{zad}}$$

Z tak spreparowanym wektorem b , program uruchamiał algorytm rozwiązujący układ $Ax = b$, generując wyliczony wektor x_{obl} . Jako miarę dokładności algorytmu przyjęto bezwzględny błąd maksymalny (metrykę zbieżną z normą nieskończoność), definiowany jako:

$$\text{Błąd}_{\text{max}} = \|x_{\text{zad}} - x_{\text{obl}}\|_{\infty} = \max_{1 \leq i \leq n} |x_{\text{zad},i} - x_{\text{obl},i}|$$

gdzie $x_{\text{zad},i}$ oraz $x_{\text{obl},i}$ to poszczególne (i -te) składowe odpowiednich wektorów. Wykorzystanie maksimum różnic wyłapuje najgorsze, punktowe załamanie dokładności w całym układzie.

Dodatkowo do analizy podatności numerycznej układu wykorzystano wskaźnik uwarunkowania macierzy (ang. **condition number**):

$$\text{cond}(A) = \|A\|_1 \cdot \|A^{-1}\|_1$$


Gdzie $\|A\|_1$ to 1-norma zdefiniowana jako maksymalna suma wartości bezwzględnych z elementów w kolumnie, a A^{-1} to macierz odwrotna do macierzy A . Współczynnik ten służy jako wyznacznik, na ile układ spotęguje mikroskopijne błędy zaokrągleń w trakcie wielokrotnych przeliczeń z zakresu algebry liniowej.

3. Analiza i wnioski: Złe uwarunkowanie (Zadanie 1)


W pierwszym ćwiczeniu badano zachowanie metody Gaussa dla macierzy A_1 , której struktura czyni ją kompletnie źle uwarunkowaną.

Tabela 1: Wybrane wyniki rozwiązania układu $A_1x = b$ metodą Gaussa

n	Błąd max (f32)	Cond (f32)	Czas [s] (f32)	Błąd max (f64)	Cond (f64)	Czas [s] (f64)
5	8.55e-03	7.99e+05	3.34e-04	1.35e-11	7.98e+05	3.48e-04
10	4.29e+01	4.99e+09	1.03e-03	1.74e-04	3.38e+13	9.88e-04
15	7.58e+01	9.28e+09	1.89e-03	8.11e+00	3.52e+17	1.86e-03
20	4.52e+01	3.20e+10	3.21e-03	2.23e+02	4.24e+18	3.23e-03



Rysunek 1: Załamanie precyzji obliczeń (błąd maks.)



Rysunek 2: Wykładniczy wzrost uwarunkowania

Wnioski merytoryczne z wykresów i danych:


- **Łańczenie precyzji obliczeń:** Na wykresie błędów (Rys. 1) wyraźnie widać różnicę między zastosowanymi typami danych. Dla pojedynczej precyzji (`float32` - krzywa czerwona) błąd staje się krytyczny i przecina próg użyteczności (> 1.0) już w okolicach $n = 7$. W precyzji podwójnej (`float64` - krzywa niebieska), dzięki większej liczbie bitów mantysy, błąd rośnie wolniej, ale nieuchronne łańczenie następuje przy $n = 12 - 13$.
- **Przyczyna numeryczna:** Rysunek 2 jednoznacznie tłumaczy to zjawisko. Wskaźnik uwarunkowania $\text{cond}(A)$ rośnie wykładniczo, osiągając dla $n = 20$ gigantyczne wartości rzędu 10^{18} . Oznacza to, że najmniejsze błędy zaokrągleń (rzędu błędu maszynowego) dodawane na każdym etapie eliminacji Gaussa, zostają wzmocnione miliardy razy. Nawet idealnie działający algorytm nie jest w stanie wygenerować poprawnego wyniku z tak wrażliwego układu.
- **Wpływ wektora x_{zad} :** Zastosowanie permutacji $\{1, -1\}$ dodatkowo uwydatnia problem. Znak naprzemiennie wymusza odejmowanie i dodawanie bliskich sobie wartości zmiennoprzecinkowych, co prowadzi do drastycznej utraty dokładności w precyzji skończonej maszynowej.

4. Analiza i wnioski: Dobre uwarunkowanie (Zadanie 2)


Macierz A_2 zaprojektowano w taki sposób, aby jej struktura gwarantowała dobrą stabilność numeryczną.

Tabela 2: Wybrane wyniki rozwiązania układu $A_2x = b$ metodą Gaussa

n	Błąd max (f32)	Cond (f32)	Czas [s] (f32)	Błąd max (f64)	Cond (f64)	Czas [s] (f64)
2	0.00e+00	3.00e+00	1.45e-04	0.00e+00	3.00e+00	1.36e-04
32	2.19e-05	1.22e+03	7.66e-03	5.86e-14	1.22e+03	7.51e-03
72	1.25e-04	6.24e+03	3.78e-02	2.21e-13	6.24e+03	3.71e-02
112	2.15e-04	1.51e+04	9.09e-02	6.28e-13	1.51e+04	8.79e-02
147	7.45e-04	2.61e+04	1.50e-01	8.09e-13	2.61e+04	1.51e-01



Rysunek 3: Błąd wyznaczania niewiadomych



Rysunek 4: Niskie uwarunkowanie macierzy

Wnioski merytoryczne z wykresów i danych:


- **Znacząca różnica uwarunkowania:** Zasadniczą różnicą między zadaniem 1 a 2 są rzędy wielkości na osiach Y (Rys. 4). Wskaźnik $\text{cond}(A)$ zachowuje tu stosunkowo niskie wartości (rzędu 10^4 dla bardzo dużych macierzy $n = 150$).
- **Sukces eliminacji Gaussa:** Dzięki powolnemu wzrostowi uwarunkowania (brak gigantycznego wzmacniania błędów wprowadzanych przez reprezentację typu float), błędy $\|x_{\text{zad}} - x_{\text{obl}}\|_{\infty}$ na Rysunku 3 przypominają niemal płaskie proste w logarytmie dla wyższych n . Błąd w precyzji `float64` utrzymuje się na poziomie praktycznie zerowym (szumu numerycznego rzędu 10^{-13}), co udowadnia, że metoda Gaussa radzi sobie wyśmienicie, jeśli rozwiązuje dobrze zdefiniowany model matematyczny.

5. Analiza i wnioski: Złożoność algorytmów (Zadanie 3)


W ostatnim zadaniu badano układ z rzadką macierzą trójdziagonalną A_3 . Rozwiązano go klasyczną metodą eliminacji Gaussa oraz specjalnie dedykowanym do takich operacji – algorytmem Thomasa.

Tabela 3: Eliminacja Gaussa vs Algorytm Thomasa dla macierzy trójdziagonalnych


n	Błąd (Gauss)	Czas [s] (G)	Pam. [KB] (G)	Błąd (Thomas)	Czas [s] (T)	Pam. [KB] (T)
10	1.11e-16	9.65e-04	6.71	1.11e-16	1.25e-04	1.12
100	2.22e-16	7.05e-02	157.34	2.22e-16	1.04e-03	6.65
300	2.22e-16	6.32e-01	1408.90	2.22e-16	3.34e-03	19.15
500	2.22e-16	1.80e+00	3910.46	2.22e-16	5.38e-03	31.65



Rysunek 5: Identyczna precyzja obu algorytmów (błąd rzędu 10^{-16})



Rysunek 6: Czas obliczeń (skala log)



Rysunek 7: Zużycie pamięci RAM (skala log)

Wnioski merytoryczne z wykresów i danych:

- Tożsamość dokładności:** Wykres błęd (Rys. 5) pokazuje idealnie nałożone na siebie, płaskie linie w okolicach zera maszynowego (10^{-16}). Oznacza to, że matematyczne uproszczenia w algorytmie Thomasa (pominięcie działań na wyzerowanych elementach wstęgi pod- i nad-diagonalnej) w żaden sposób nie degradują precyzji w stosunku do pełnego, klasycznego Gaussa.
- Przepaść wydajnościowa (Czas obliczeń):** Wykres czasowy na skali logarytmicznej (Rys. 6) uwidacznia fundamentalną różnicę w asymptotycznej złożoności. Klasyczny Gauss analizujący całą macierz wykazuje złożoność sześcienną $O(n^3)$ (fioletowa krzywa). Algorytm Thomasa cechuje się złożonością liniową $O(n)$ – dla układu równań z $n = 500$ niewiadomymi rozwiązanie trwa ułamek milisekundy w przeciwieństwie do niemal 2 sekund Gaussa, co tworzy widoczną na rysunku przepaść wydajnościową.
- Optymalizacja alokacji pamięci:** Wykres użycia pamięci podręcznej RAM (Rys. 7) udowadnia przewagę w podejściu do przechowywania danych. Metoda Gaussa wymusza przechowywanie całej kwadratowej macierzy (w większości składającej się z neutralnych zer),

co narzuca złożoność alokacyjną $O(n^2)$. Z kolei implementacja algorytmu Thomasa ładuje jedynie macierz pasmową wielkości $n \times 3$, redukując zużycie do poziomu $O(n)$. Taki zabieg pozwala zaoszczędzić systemowi gigantyczne zasoby przy przeliczaniu skomplikowanych układów macierzowych, redukując dla $n = 500$ obciążenie z ok. 4000 KB pamięci operacyjnej do zaledwie 31 KB.